



MÉMOIRE DE STAGE DE 2ÈME ANNÉE

---

# Traitement de données de calibration de télescope d'observation de la Terre

---

PETITPOISSON Maxime

PROMOTION 2024

FILIÈRE INFORMATIQUE ET RÉSEAU  
SCIENCE DES DONNÉES ET SYSTÈMES COMPLEXES

2022/2023

22/05/2023 - 13/08/2023

*Organisme d'accueil*  
Centre Spatial de Liège



*Tuteur école :*  
HABET ADLANE  
habed@unistra.fr

*Tuteur entreprise :*  
CLERMONT LIONEL  
Lionel.Clermont@uliege.be

## Remerciements

Je tiens à exprimer ma sincère gratitude envers toute l'équipe du Centre Spatial de Liège (CSL) pour m'avoir accueilli au sein de leur institution tout au long de mon stage. Cette expérience a été exceptionnelle et enrichissante, me permettant de plonger au cœur de l'univers passionnant de la recherche spatiale et de la technologie des capteurs. Les précieux enseignements, les conseils avisés, et l'opportunité de travailler aux côtés de professionnels chevronnés du CSL ont été d'une valeur inestimable pour mon développement personnel et professionnel. Je tiens également à remercier Lionel Clermont pour son soutien et sa patience tout au long de mon stage. Cette expérience restera un moment clé dans mon parcours, et je suis reconnaissant pour cette opportunité inoubliable.

# Table des matières

<b>Remerciements</b>	<b>i</b>
<b>Résumé</b>	<b>iii</b>
<b>Introduction</b>	<b>1</b>
<b>Présentation de l'entreprise</b>	<b>2</b>
<b>Contexte technique</b>	<b>5</b>
I. Les principes de la stray light . . . . .	5
I.1. Fondamentaux . . . . .	5
I.2. Ghosts . . . . .	6
II. L'algorithme de correction de la stray light . . . . .	7
II.1. Mesure de la correction . . . . .	7
II.2. Calibration d'un champs . . . . .	8
II.3. Algorithme itératif . . . . .	8
II.4. Optimisations . . . . .	10
<b>Travail effectué</b>	<b>11</b>
I. Pourquoi le deep learning . . . . .	11
II. La fusion d'images . . . . .	12
II.1. Visualisation des données . . . . .	12
II.2. Prétraitement . . . . .	13
II.3. Le modèle UNet . . . . .	13
II.4. Les hyperparamètres . . . . .	16
II.5. Les résultats . . . . .	18
III. L'interpolation d'images . . . . .	20
III.1. Définition des FPST . . . . .	20
III.2. La méthode choisie . . . . .	20
III.3. Les différents modèles . . . . .	21
III.4. Les hyperparamètres . . . . .	23
III.5. Les résultats . . . . .	24
<b>Conclusion</b>	<b>26</b>
<b>Bibliographie</b>	<b>27</b>

## Résumé

### *Traitement de données de calibration de télescope d'observation de la Terre*

Le stage au Centre Spatial de Liège était axé sur l'amélioration des performances des instruments optiques, en particulier l'instrument d'observation de la Terre, 3MI. Le défi central consistait à corriger la lumière parasite, un problème crucial dans le domaine spatial, pouvant affecter la qualité des données collectées et le succès des missions. L'objectif du stage était de remplacer certaines parties de l'algorithme de correction par des techniques d'apprentissage profond.

Pour relever ce défi, des techniques d'apprentissage profond ont été intégrées dans le modèle UNet utilisé pour la fusion d'images. L'entraînement de ce modèle a été compliqué par des problèmes de surapprentissage. Cependant, cet obstacle a été surmonté en mettant en œuvre des techniques telles que le dropout, la batch normalization, la régularisation L2, l'optimisation de la taille du réseau et l'early stopping.

Le stage s'est également intéressé à l'interpolation d'images, visant à augmenter la résolution des images à partir d'une grille de calibration de 27x27 vers une grille de 64x64. Différentes architectures de modèles de super-résolution, telles que SRCNN, VDSR, FSRCNN et ESPCNN, ont été explorées pour atteindre cet objectif.

En conclusion, cette expérience au CSL a été enrichissante. Elle a permis de proposer des solutions prometteuses à un problème complexe de correction de la lumière parasite en utilisant l'apprentissage profond. Les résultats obtenus ouvrent la voie à de futures avancées dans le domaine des instruments optiques spatiaux et de l'observation de la Terre, renforçant ainsi la position du Centre Spatial de Liège en tant qu'acteur clé de l'exploration spatiale.

### *Processing Earth Observation Telescope Calibration Data*

My internship at the Liège Space Center focused on improving the performance of optical instruments, particularly the Earth observation instrument, 3MI. The central challenge was to correct stray light, a critical issue in the space domain that could impact the quality of collected data and mission success. The goal of the internship was to replace parts of the correction algorithm with deep learning techniques.

To tackle this challenge, deep learning techniques were integrated into the UNet model used for image fusion. Training this model was complicated by overfitting issues. However, this obstacle was overcome by implementing techniques such as dropout, batch normalization, L2 regularization, network size optimization, and early stopping.

The internship also delved into image interpolation, aiming to increase the resolution of images from a 27x27 calibration grid to a 64x64 grid. Various super-resolution model architectures, such as SRCNN, VDSR, FSRCNN, and ESPCNN, were explored to achieve this goal.

In conclusion, this experience at CSL was enriching. It led to promising solutions for a complex problem of stray light correction using deep learning. The results obtained pave the way for future advancements in the field of space optical instruments and Earth observation, thereby strengthening the position of the Liège Space Center as a key player in space exploration.

## Introduction

Le présent rapport de stage relate une expérience professionnelle enrichissante de trois mois au sein du Centre Spatial de Liège, une institution de renom dans le domaine de l'exploration spatiale et de l'observation de la Terre. Mon stage, intégré dans un projet plus vaste, s'inscrit dans le cadre de la recherche visant à améliorer les performances des instruments optiques de haute précision.

Au cœur de ces missions spatiales, l'élément central est l'instrument optique, dont la performance détermine la qualité des images obtenues. Même en présence d'une correction des aberrations optiques de grande qualité, un autre défi majeur se pose : la lumière parasite. Les conséquences de cette lumière parasite sont multiples, notamment la dégradation de la résolution et du rapport signal/bruit des images. Elle compromet également l'observation d'objets faibles ou de hautes fréquences spatiales. Dans le contexte spatial, où les exigences de performance sont strictes, la lumière parasite peut même déterminer le succès ou l'échec d'une mission.

Ainsi, la maîtrise de la lumière parasite est cruciale dans le développement des instruments spatiaux. Elle nécessite une conception opto-mécanique intelligente et une sélection de matériaux appropriés. Pour anticiper et résoudre ce problème, le Centre Spatial de Liège (CSL) s'est imposé comme un acteur majeur, contribuant significativement à la conception et à la mise en œuvre d'instruments optiques avancés pour l'observation de la Terre et l'exploration spatiale. Mon stage a été supervisé par le Dr. Clermont Lionel, auteur de la thèse *Stray light control in space instruments : overcoming the conventional limits* ([7]) qui a servi de base à notre projet.

Le projet global auquel s'inscrit mon stage vise à développer une solution de correction des aberrations de lumière parasite affectant les performances des instruments optiques de haute précision, en mettant particulièrement l'accent sur l'instrument d'observation de la Terre, 3MI. Ce dernier présente des propriétés complexes en matière de lumière parasite en raison de la présence de multiples artefacts répartis sur son réseau de détecteurs. L'article de référence décrit une méthode de correction itérative et discute de ses propriétés de convergence.

Mon travail lors de ce stage a consisté à introduire des techniques d'apprentissage profond (deep learning) pour remplacer certaines parties de l'algorithme de correction de lumière parasite. L'objectif principal était d'améliorer la généralisation de ces tâches, et d'augmenter leur robustesse, afin de limiter le besoin de corrections humaines et d'ajustements, qui peuvent prendre plusieurs mois.

## Présentation de l'entreprise

Le Centre Spatial de Liège (CSL) est un acteur majeur dans le domaine de l'instrumentation spatiale et de la technologie des capteurs. Il opère dans le secteur de la recherche et du développement, en mettant l'accent sur les avancées scientifiques et technologiques nécessaires pour soutenir les missions spatiales. Le CSL travaille en étroite collaboration avec l'Agence spatiale européenne (ESA) et d'autres partenaires internationaux pour la réalisation de projets spatiaux d'envergure.

Le CSL a été fondé en 1964 et s'est depuis affirmé comme un centre de référence dans les sciences spatiales en Belgique. Depuis sa création, le CSL a participé à de nombreux projets spatiaux importants, en développant des instruments de pointe et des technologies novatrices. Grâce à son expertise reconnue, le CSL est devenu un partenaire incontournable pour les missions spatiales nationales et internationales.

Le CSL compte actuellement environ 100 employés, comprenant des chercheurs, des ingénieurs, des techniciens et du personnel administratif. Il se structure en différents services et équipes, chacun spécialisé dans des domaines spécifiques de l'instrumentation spatiale. Ces équipes travaillent en étroite collaboration pour concevoir, développer, tester et valider des instruments et des équipements destinés à être embarqués sur des satellites et des sondes spatiales. L'organigramme en FIGURE 1 illustre l'organisation du CSL :

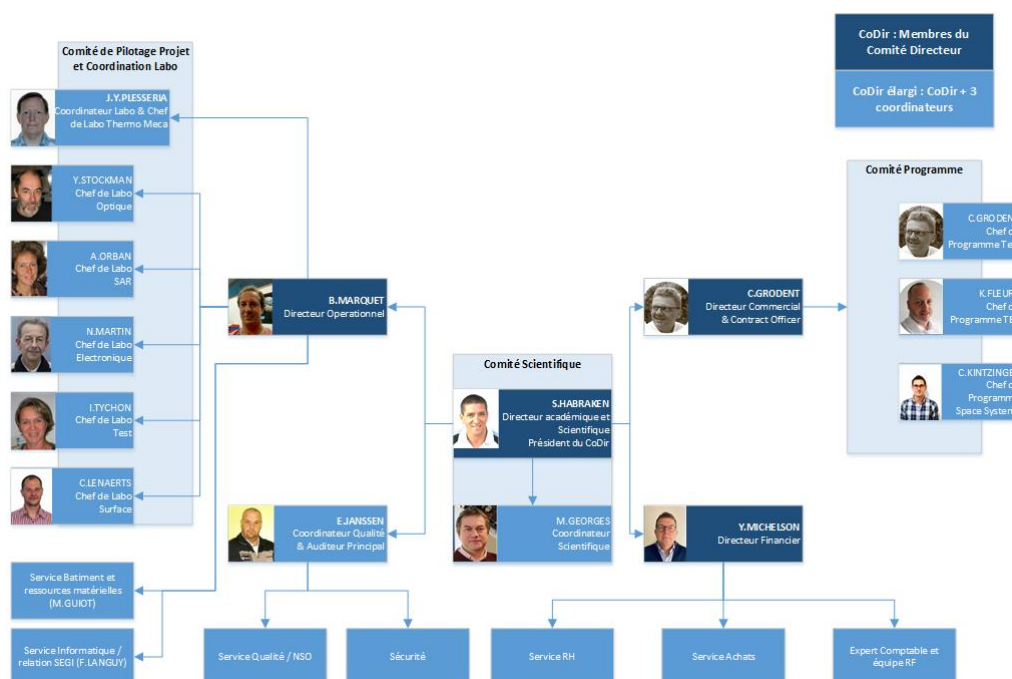


FIGURE 1 – Organigramme du CSL (provenant du site du CSL)

En ce qui concerne le budget ou le chiffre d'affaires, le CSL est financé principalement par des fonds publics provenant de différents partenaires, tels que le gouvernement belge, l'Agence spatiale européenne (ESA) et d'autres organismes de recherche nationaux et internationaux. Le CSL reçoit également des financements pour des projets spécifiques, provenant de l'ESA et d'autres organisations spatiales.

Le CSL travaille en étroite collaboration avec des clients de renommée mondiale, tels que l'ESA, pour la réalisation de missions spatiales. Il fournit des services et des solutions technologiques dans le domaine de l'instrumentation spatiale, des capteurs et des systèmes de mesure. Parmi les fournisseurs du CSL, on compte des partenaires industriels spécialisés dans la fabrication de composants et d'instruments spatiaux. Le CSL entretient des partenariats solides avec des entreprises spatiales de premier plan pour assurer l'intégration et la mise en œuvre réussie de ses instruments dans les missions spatiales.

Le CSL est situé à Liège, en Belgique, où il dispose de locaux modernes et bien équipés pour mener à bien ses activités de recherche et de développement. Bien que son siège principal soit à Liège, le CSL collabore avec des partenaires internationaux et participe à des projets spatiaux à travers le monde, contribuant ainsi à des missions scientifiques d'envergure. Sa situation géographique stratégique facilite également les collaborations avec d'autres centres de recherche et acteurs de l'industrie spatiale en Europe et dans le monde.

Le CSL dispose d'une salle blanche, qui est un grand hangar, qui joue un rôle essentiel dans la préparation et l'intégration des instruments spatiaux. La salle blanche est un environnement contrôlé où le taux de particules dans l'air est maintenu à un niveau extrêmement bas pour éviter toute contamination des équipements sensibles. Cette salle est équipée de filtres de haute performance, d'un contrôle strict de la température et de l'humidité, et d'une régulation de la pression atmosphérique. Ces mesures garantissent un environnement propre et sûr pour l'assemblage des instruments spatiaux, minimisant ainsi les risques de dysfonctionnement pendant les missions en orbite.

On accède à la salle blanche uniquement en portant une charlotte, une blouse et des couvre-pieds. Elle est compartimentée en blocs délimités par des "murs invisibles". A l'aide d'un système de pompage, des flux laminaires sont utilisés pour créer des murs de vent, qui poussent les particules hors de ces 'salles' d'expérience. Ainsi, elles peuvent être gardées à une limite de moins de 100 particules par mètres cube, contre 10000 pour le reste de la salle blanche. Cette limite, qui détermine la norme ISO5, est essentielle car la poussière, en trop grande quantité, fausse les mesures en diffusant la lumière.



Au sein de la salle blanche, les équipes du CSL effectuent des opérations délicates telles que le montage et l'alignement précis des capteurs, la calibration des instruments et les tests de résistance aux conditions extrêmes de l'espace. Cette installation hautement spécialisée permet au CSL de produire des instruments fiables et de haute qualité, répondant aux exigences strictes des missions spatiales modernes.

En résumé, le Centre Spatial de Liège (CSL) est un centre de recherche et de développement spécialisé dans l'instrumentation spatiale et la technologie des capteurs. Avec une histoire riche, une organisation structurée et une présence géographique internationale, le CSL est un acteur clé dans le domaine des sciences spatiales, collaborant avec des clients prestigieux et des fournisseurs spécialisés pour soutenir les missions spatiales, promouvoir l'innovation technologique et garantir la qualité des équipements grâce à sa salle blanche de pointe.

## Contexte technique

### I. Les principes de la stray light

La lumière parasite, ou "stray light" en anglais, est un phénomène omniprésent et essentiellement indésirable dans les systèmes optiques d'imagerie tels que les appareils photos, les télescopes, ou les microscopes. Son impact sur la qualité des images obtenues est significatif, ce qui en fait un sujet de préoccupation majeure pour les ingénieurs et les chercheurs travaillant dans le domaine de l'optique. Dans cette section sera exploré le principe de la lumière parasite, ses sources potentielles, les différents chemins qu'elle peut emprunter, ainsi que son influence néfaste sur les images capturées.

#### I.1. Fondamentaux

Dans un système optique d'imagerie, tel qu'un appareil photo, un télescope, ou un microscope, différents éléments sont utilisés pour concentrer la lumière de l'objet que l'on souhaite observer sur un détecteur. Ces éléments incluent les lentilles, les miroirs, les ouvertures, les masques, etc. Cependant, il peut exister d'autres chemins dans le système qui permettent à la lumière de parvenir au détecteur. C'est cette lumière que l'on appelle la lumière parasite.

Les moyens qui permettent l'apparition de lumière parasite sont nombreux. Tout d'abord, la source lumineuse peut soit provenir du champ de vision du détecteur, soit de l'extérieur du champ de vision (par exemple le soleil), soit provenir de l'appareil lui-même (auto émission thermique). Les chemins détournés peuvent être divisés en trois grandes catégories : les réflexions fantômes, la diffraction et les chemins directs. Les réflexions fantômes étant le principal contributeur de lumière parasite dans le cas du détecteur 3MI, elles seront présentées plus en détail. La diffraction peut arriver à diverses endroits du système optique tels que les parois, les ouvertures, les masques, etc, et consiste en ce que la lumière est diffusée dans toutes les directions après sa rencontre avec l'élément. Les trajets directs, très rares, arrivent lorsqu'il existe un chemin optique direct entre la source lumineuse et le détecteur. Ils sont souvent détectés et corrigés lors de la conception du système optique.

Les conséquences de la lumière parasite sur les images capturées sont significatives. Elle introduit des éléments indésirables dans l'image, perturbant ainsi sa qualité et sa clarté. De plus, la lumière parasite a tendance à élargir la fonction de transfert du point (PSF), qui est essentielle pour la résolution d'image. Cette distorsion nuit au rapport signal/bruit (SNR) en rendant les détails plus difficiles à discerner. En conséquence, la résolution globale de l'image est réduite, affectant ainsi la capacité à extraire des informations précises à partir de l'image capturée.

## I.2. Ghosts

Cette section présente plus en détail le phénomène des réflexion fantôme.

La réflexion fantôme est un processus fréquent dans les systèmes optiques réfractifs, et elle représente souvent une source significative de lumière parasite. Elle se produit lorsque la lumière est partiellement réfléchie aux interfaces des éléments optiques réfractifs, même lorsque ces surfaces sont revêtues d'un revêtement antireflet. Le phénomène se produit principalement entre les lentilles d'un système optique.

Soit un faisceau lumineux qui traverse un système optique composé de plusieurs lentilles. À chaque interface lentille-air ou lentille-lentille, une petite fraction de la lumière est réfléchie. Cette lumière réfléchie suit un chemin différent de celui du faisceau principal, rebondissant entre les lentilles et pouvant finalement atteindre le détecteur. Ce processus est illustré par la FIGURE 2 (a). Ce processus génère ce que l'on appelle des motifs fantomatiques, ou simplement "fantômes", sur le détecteur. Ces fantômes se superposent à l'image principale capturée par le système optique.

Par exemple, dans une image capturée avec un appareil photo commercial, les fantômes peuvent apparaître sous forme de motifs géométriques, ressemblant au diaphragme. Ce type de fantôme est représenté dans la FIGURE 2 (b).

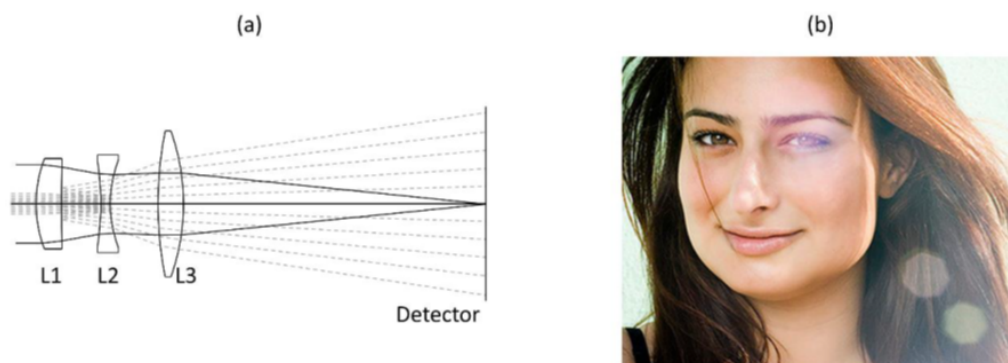


FIGURE 2 – (a) Processus de formation de réflexion fantôme. (b) Fantôme sur une caméra commerciale [6]

## II. L'algorithme de correction de la stray light

### II.1. Mesure de la correction

Il existe deux manières de mesurer la quantité de lumière parasite produite par une scène. La première est de créer l'éclairage correspondant et de réaliser des mesures avec le détecteur. Cependant, ce processus prend du temps. Il est également possible de simuler la quantité de lumière parasite en utilisant des algorithmes de tracé de rayon (ray casting). Ces méthodes consistent à simuler un certain nombre de rayons lumineux partant des sources de lumières. On calcul alors leur trajet à partir du détecteur, qui a été modélisé sur un logiciel, et on obtient alors la quantité de lumière parasite. Cette méthode a l'avantage de pouvoir tourner la nuit, et de fournir l'origine de la lumière parasite en plus de la quantité. Toute modélisation étant imparfaite, les prédictions sont donc cependant moins précises.

L'étude de la lumière parasite se fait souvent sur des scènes lumineuses étendues, et notamment la scène 'Black and White'. Celle-ci présente une moitié du champ de vision illuminée, et une autre moitié sombre (les coins sont sombres car le champ de vision est un cercle). Cette scène souvent utilisée en observation de la terre, car on observe souvent des transitions entre différentes illuminations (terre/mer, ciel/nuage,...). On peut observer en FIGURE 3 cette scène et la lumière parasite prédite par un tracé de rayon.

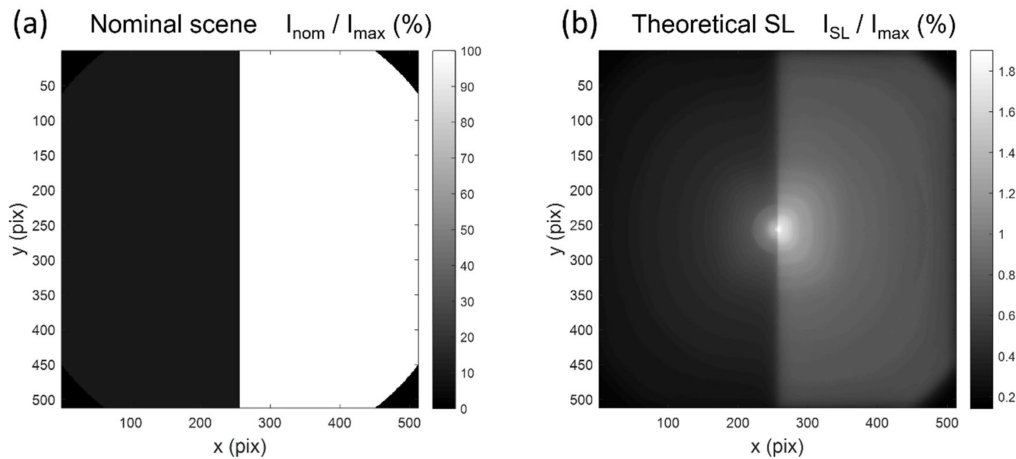


FIGURE 3 – Scène lumineuse étendue 'Black and White' et la lumière parasite correspondante [6]

L'objectif de l'algorithme de correction est de retrouver cette lumière parasite théorique sans avoir accès à la scène nominale (la scène originale). On mesure donc la performance de l'algorithme en fonction de la différence entre la prévision de l'algorithme et la 'réalité'. Dans le cas du détecteur 3MI, l'objectif de précision se situait à 0.017% de l'intensité maximale de la scène nominale.

## II.2. Calibration d'un champs

Le première étape de l'algorithme de correction consiste à calibrer l'appareil pour des champs individuels. On définit la SPST (spatial point source transmittance ou transmittance spatiale d'une source ponctuelle) comme la carte de la lumière parasite reçue par le détecteur lorsqu'il est éclairé par une source ponctuelle. Ainsi, on nomme  $SPST_{i,j}$  la carte de la lumière parasite reçue par le détecteur lorsque la partie correspondant au pixel  $i,j$  du détecteur est illuminée. Une telle SPST est présentée en FIGURE 4.




FIGURE 4 –  $SPST_{235, 315}$

Les SPST sont obtenues en calibrant réellement le détecteur, cela prend donc un temps conséquent pour les obtenir, ce qui pose problème comme cela sera exposé plus loin.

## II.3. Algorithme itératif

Le signal reçu par le détecteur est la somme du signal nominal et de la lumière parasite (voir 1).

$$I_{\text{mes}} = I_{\text{nom}} + I_{\text{SL}} \quad (1)$$

En calibrant tous les champs du champ de vision du détecteur, il est assez simple d'obtenir la lumière parasite d'une scène étendue : on ajoute linéairement les SPST de tous les pixels allumés de la scène, pondérées par leur intensité.

$$I_{\text{SL}} = \sum_{i,j}^N SPST_{i,j} \cdot I_{\text{Nom}}(i,j) \quad (2)$$

On peut alors définir une matrice  $N^2 \times N^2$   $A_{\text{SL}}$  telle que :

$$I_{\text{SL}} = A_{\text{SL}} \cdot I_{\text{Nom}} \quad (3)$$

A l'aide des équations 1 et 3, on peut alors déduire une formule pour récupérer la scène nominale :

$$I_{\text{nom}} = (id + A_{\text{SL}})^{-1} \cdot I_{\text{mes}} \quad (4)$$

Cette approche présente de nombreux inconvénients. D'abord, la taille de  $A_{\text{SL}}$  qui dans le cas de 3MI est d'environ  $6.9 \times 10^{10}$ . Cela rend le processus d'inversion de matrice très coûteux. De plus, ce dernier peut conduire à des erreurs d'approximation. Enfin, l'inversion de matrice force  $A_{\text{SL}}$  à être carrée, ce qui limite l'utilisation de certaines optimisations.

Pour répondre à ces problèmes, une approche itérative plus flexible est préférée dans le cas du détecteur 3MI. Pour cela, on part de l'équation 3 en remplaçant  $I_{\text{Nom}}$  par  $I_{\text{mes}}$ . On approxime donc la scène mesurée à la scène nominale en se basant sur le fait qu'elles sont très proches, et donc fourniront une approximation de la lumière parasite proche. On affine ensuite cette approximation en remplaçant la scène nominale par la scène mesurée moins notre première prédiction de lumière parasite. On répète ensuite ce cycle un certain nombre de fois.

$$I_{\text{SL},0} = 0 \quad (5)$$

$$I_{\text{SL},p} = A_{\text{SL}} \cdot (I_{\text{mes}} - I_{\text{SL},p-1}) \quad (6)$$

$$I_{\text{corr},p} = I_{\text{mes}} - I_{\text{SL},p} \quad (7)$$

Les propriétés de convergence et d'erreur de cet algorithme sont étudiées dans l'article sur lequel se base les dernières parties.

## II.4. Optimisations

Seul, l'algorithme présenté n'est pas exploitable dans le cas du détecteur 3MI. Il faut lui adjoindre des optimisations qui le rendront applicable et performant.

### II.4.a. Regroupement spatial et regroupement par domaine

Le détecteur 3MI a une résolution de 512 par 512 pixels. Cela implique que la matrice  $A_{SL}$  est de taille  $6.9 \times 10^{10}$ . Cela pose problème même avec un algorithme itératif. On applique donc des regroupements qui réduisent la taille de  $A_{SL}$  et réduisent le temps de calcul de la lumière parasite. le regroupement spatial consiste à réduire la résolution des SPST en faisant des moyennes sur les pixels du détecteur. Le regroupement par domaine consiste à réduire le nombre de SPST en faisant des moyennes sur les domaines du champ de vision. Les deux techniques réduisent respectivement le nombre de lignes et de colonnes de  $A_{SL}$ . Pour appliquer ces techniques à l'algorithme de l'inversion de matrice, il faudrait donc des réductions identiques pour garder la matrice carrée, mais dans le cas de l'algorithme itératif, ces restrictions n'existent pas.

### II.4.b. Interpolation

Comme il a été évoqué, le calcul des SPST est long et coûteux. Hors, si l'on voulait calibrer tous les champs du détecteur, il faudrait réaliser plus de 200000 mesures. C'est absolument impossible. Il faut donc trouver une alternative. Comme dans le cas du regroupement par domaine ou l'on ne considère qu'un certain nombre de champs, on peut de la même manière ne calibrer qu'un certain nombre de champs. On peut alors se donner une grille de calibration de taille  $k \times k$  et utiliser les mêmes techniques que pour le regroupement par domaine. Cependant pour obtenir les performances attendues dans le cas de 3MI, il faudrait une grille de calibration de  $180 \times 180$ . Hors, dans un temps raisonnable, seul une grille de  $27 \times 27$  peut être calibrée. Il faut donc interpoler les SPST manquantes.

### II.4.c. Décomposition de plage dynamique

Lors de la calibration d'un champ, il est crucial d'obtenir une image d'excellente qualité. Hors, la lumière parasite est par essence très tenue. Le contraste entre l'intensité de la lumière parasite et la source lumineuse rend donc complexe l'acquisition d'une SPST de bonne qualité. Effectivement si l'on choisit un temps d'exposition suffisant pour capter les détails de la lumière parasite, les champs alentours de la source lumineuse seront saturés, et si l'on choisit un temps d'exposition trop faible, le reste de l'image ne sera constitué que de bruit. On choisit donc de réaliser 3 mesures avec des temps d'expositions différents et de les combiner.

# Travail effectué

## I. Pourquoi le deep learning

La motivation première dans la tentative de développer des modèles de deep learning pour remplacer certaines parties de l'algorithme de correction de la lumière parasite est la robustesse et la généralisation. Dans le cas de la décomposition de plage dynamique, la fusion des différentes expositions demande des ajustements incessants, et peut prendre un temps considérable. Elle doit aussi être adaptée à chaque détecteur, voir à chaque expérience. Dans l'idéal, avec un modèle de deep learning, cet ajustement serait mineur voir inexistant.

Quand à l'interpolation, les meilleurs résultats sont obtenus en exploitant des propriétés de symétrie qui ne s'étendent pas nécessairement à d'autres détecteurs. Un algorithme de deep learning qui obtiendrait des résultats similaire permettrait de poser les bases d'une solution plus facile à mettre en place pour de nouveaux détecteurs.



## II. La fusion d'images

La première tâche de ce stage consistait à tenter de reproduire les résultats de la décomposition de plage dynamique à l'aide de techniques de deep learning.

### II.1. Visualisation des données

Les données de travail pour cette partie étaient les images de calibration (SPST), et plus précisément les mesures réalisées avec 3 temps d'expositions différents. Les données se trouvaient sous la forme de fichiers .mat et contenaient les images des 3 mesures, les reconstructions effectuées par l'équipe de chercheurs du CSL (qui serviront de label), ainsi que les angles correspondants à la position du champs observé. Ces données étaient disponible pour les différents canaux du détecteur 3MI (ce dernier est doté de détecteur dans différentes longueurs d'ondes et polarisations).

La figure 5 montre un exemple des 3 mesures de calibration et de la reconstruction cible. Les zones "évidées" dans les images 2 et 3 correspondent aux parties saturées. L'image 1 correspond au temps d'exposition le plus court, et on remarque que la partie correspondant à la source lumineuse est visible (point rouge) mais que le reste est constitué de bruit. De même, la partie autour de la source est visible sur l'image 2 mais le reste est bruité, et à part la partie saturée de l'image 3, le reste est net.

Pour la visualisation des images en FIGURE 5, les images ont été mises dans une échelle logarithme, car les variations d'intensité sont très faible. L'image recombinaison apparaît plus sombre car la partie correspondant à la source lumineuse est la plus intense. Ainsi, le reste de l'image paraît plus sombre.




FIGURE 5 – Les différentes images de calibration et la reconstruction de la SPST

## II.2. Prétraitement

Le prétraitement appliqué consiste à remplacer les valeurs nulles par des valeurs très faible, puis à appliquer un logarithme en base 10. Les images sont ensuite normalisées entre 0 et 1 par le maximum et le minimum global des images. On coupe ensuite les images autour de la partie qui nous intéresse (le voisinage de la source lumineuse). Le carré obtenu fait alors 128 par 128 pixels. Les trois images de mesures sont alors "collées" entre elles pour obtenir une donnée de dimension  $128 \times 128 \times 3$ . Les données et le label sont alors séparés en jeu d'entraînement et de test à hauteur de 80% / 20%.

## II.3. Le modèle UNet

Lors de la lecture d'articles sur le sujet de la fusion d'images et notamment de la MEF (multi exposure fusion), tel que [1], [3], [4] ou [5], il est apparu que dans le cadre du deep learning, les modèles convolutionnels étaient les plus abordables. Il a

été décidé de retenir l'architecture du UNet car celle-ci est à la fois très puissante et facilement réalisable.

### II.3.a. Présentation du réseau UNet

La caractéristique principale de l'UNET est sa structure en forme de "U," d'où son nom. Cette architecture se compose de trois parties fondamentales : l'encodeur, le "bottleneck" (col de bouteille) et le décodeur.

- L'encodeur est la première moitié du réseau. Son rôle est de réduire progressivement la résolution spatiale de l'image en extrayant des caractéristiques pertinentes à différents niveaux d'abstraction. Il utilise des couches de convolution pour capturer des informations significatives tout en réduisant la dimension.
- Le "bottleneck," que l'on peut traduire en français par "col de bouteille," est une partie cruciale de l'architecture UNet. Cette section étroite et centrale du réseau agit comme un goulot d'étranglement où l'information est fortement compressée. On appelle souvent cette partie le "latent space" ou "feature space" car c'est une partie du réseau où l'information est réduite en dimension et réduite à ses caractéristiques principales. Il est intéressant de réaliser les opérations ici car cela nécessite moins de calculs. Cela permet à l'UNet de concentrer ses efforts sur les caractéristiques les plus importantes tout en maintenant une efficacité de traitement élevée.
- Le décodeur est la seconde moitié du réseau. Il prend les caractéristiques extraites par l'encodeur et les utilise pour reconstruire une image de la taille d'origine. Cela se fait en agrandissant progressivement l'image tout en ajoutant des détails grâce à des couches de déconvolution.

Les "skip connections," que l'on peut traduire en français par "connexions sautées" ou "connexions de saut," sont une autre caractéristique clé de l'architecture UNET. Ces connexions établissent des liens directs entre les couches de l'encodeur et du décodeur à des niveaux de résolution similaires. Cette technique permet au décodeur d'accéder aux informations détaillées extraites par l'encodeur à différents niveaux d'abstraction. Les skip connections aident à améliorer la qualité de la reconstruction en fournissant des informations contextuelles importantes qui peuvent être perdues dans d'autres architectures de réseau. Elles jouent un rôle essentiel dans la préservation des détails et la précision des opérations sur les images réalisées par l'UNet.

### II.3.b. Implémentation du réseau UNet

L'implémentation du réseau a été effectuée en python, en créant une classe personnalisée, et en utilisant le framework keras comme base. L'architecture finale est présentée en FIGURE 6.

On retrouve en rose l'encodeur, qui alterne les couches convolutionnelles et les couches de "max pooling" (couches qui réduisent la taille des données en prenant le maximum d'un groupe de pixels). Cette couche transforme progressivement des données constituées de 3 images de  $128 \times 128$  pixels en un block de données plus étroit mais plus profond, jusqu'à arriver à des données de taille  $32 \times 32 \times 256$ . La taille des données a donc été divisée par 4, mais il y a maintenant de nombreux filtres qui encodent des parties spécifiques des images (256).

En vert est représenté la partie "bottleneck" du réseau. Celle-ci est constituée de couches convolutionnelles qui ne modifient pas la taille des données, mais qui vont réaliser des opérations. Il est pertinent de penser que c'est à cette étape que se réalise la fusion des 3 images, bien que celle-ci se réalise de manière diffuse dans l'ensemble du réseau.

Enfin, en bleu, on retrouve la partie décodeur du réseau. Celle-ci a un rôle inverse de celui de l'encodeur, et a pour tâche de rendre aux données leur dimension d'origine. Pour cela, on alterne des couches convolutionnelles et d'agrandissement qui répètent les pixels pour augmenter la taille de l'image. Les couches convolutionnelles reçoivent aussi en entrée les sorties des couches convolutionnelles de l'encodeur, par des "skip connection". Cela a pour but de ne pas perdre les détails les plus fins des images. Comme on souhaite à la fin n'avoir qu'une seule image reconstruite, la sortie de la dernière convolution aura pour dimension :  $128 \times 128 \times 1$ .

On utilise pour entraîner le modèle l'erreur quadratique moyenne et l'optimiseur Adam de la bibliothèque keras.

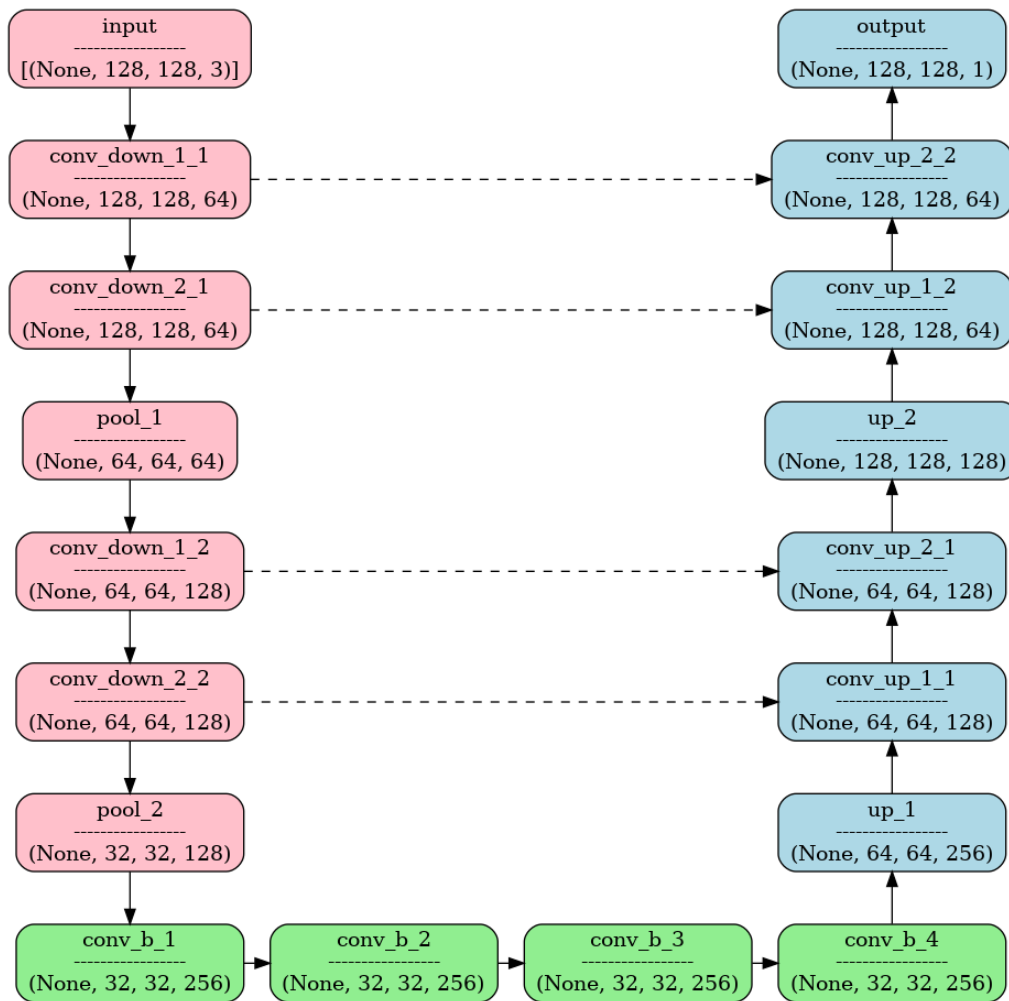


FIGURE 6 – La représentation de l'architecture UNet utilisée

## II.4. Les hyperparamètres

La problématique du surapprentissage est un défi majeur à prendre en compte dans la tâche de fusion d'images en utilisant un modèle UNet. Cette difficulté découle principalement de la quantité limitée de données d'entraînement, soit environ 2500 exemples, ce qui rend le modèle vulnérable au surapprentissage, où il mémorise les données au lieu de généraliser.

La gestion de cette problématique repose sur l'ajustement précis des hyperparamètres du modèle. Des hyperparamètres tels que la taille du réseau, le taux d'apprentissage, la régularisation et la méthode d'optimisation ont été minutieusement calibrés pour prévenir le surapprentissage. Par exemple, des techniques de régularisation comme la dropout et la régularisation L2 ont été explorées pour réduire la complexité du modèle et atténuer le risque de surapprentissage.

Dans le but de déterminer les meilleures combinaisons d'hyperparamètres, une tentative de mise en œuvre d'une recherche systématique, tel que le grid search, a été entreprise. Cependant, cette tentative s'est soldée par un échec en raison de deux facteurs majeurs. Tout d'abord, une implémentation défectueuse du grid search a entravé son bon fonctionnement. De plus, en raison d'un manque d'expérience, les résultats des expériences individuelles n'ont pas été sauvegardés. Ce ne sera pas le cas pour la seconde partie du stage.

Ces difficultés mettent en évidence la complexité inhérente à la recherche d'hyperparamètres, en particulier lorsque les données d'entraînement sont limitées. Elle souligne également l'importance critique de la mise en place de processus d'expérimentation robustes et de la gestion des erreurs pour garantir la fiabilité des résultats.

Afin de relever les défis du surapprentissage et de l'ajustement des hyperparamètres dans le contexte de la fusion d'images avec un modèle UNet, un ensemble de techniques spécifiques a été déployé. Ces techniques ont été soigneusement sélectionnées pour améliorer la performance du modèle tout en minimisant les risques de surapprentissage. Ci-dessous, sont présentées de manière concise les principales techniques mises en œuvre :

1. *Dropout* : Pour réduire la complexité du modèle UNet, la technique de dropout a été intégrée. Elle consiste à désactiver aléatoirement un pourcentage des neurones lors de l'entraînement, ce qui empêche le modèle de devenir excessivement dépendant de certaines connexions et de mieux généraliser. La valeur finale utilisée est un taux de dropout de  $0.1$ .
2. *Batch Normalization* : La batch normalization a été appliquée à chaque couche du modèle UNet. Cette technique normalise les activations à l'intérieur de chaque mini-batch, ce qui accélère la convergence de l'apprentissage et améliore la stabilité du modèle.
3. *Régularisation L2* : Une régularisation L2 a été appliquée aux poids du modèle. Elle pénalise les poids plus importants, ce qui réduit la tendance du modèle à surapprendre en limitant la magnitude des poids. La valeur finale utilisée est un weight decay de  $0.0005$ .
4. *Optimisation de l'Hyperparamètre de la Taille du Réseau* : Pour trouver le bon équilibre entre la capacité du modèle et le risque de surapprentissage, différentes architectures de modèles UNet ont été explorées. Cela comprenait des variations de la taille du réseau, en ajustant le nombre de couches et le nombre de filtres par couche. Cette approche a permis de rechercher la meilleure configuration pour la tâche spécifique de fusion d'images. L'architecture est celle présentée en figure FIGURE 6.
5. *Early Stopping* : Pour éviter le surapprentissage, la technique d'early stopping a été utilisée. Elle consiste à surveiller la performance du modèle sur un

ensemble de validation pendant l'entraînement et à arrêter l'entraînement lorsque la performance cesse de s'améliorer, ce qui évite que le modèle ne s'adapte de manière excessive aux données d'entraînement.

Avec toutes ces améliorations, on arrive à entraîner un modèle satisfaisant. L'erreur de validation reste erratique, mais un arrêt prématuré et une récupération du meilleur modèle de l'entraînement permet de palier à ce problème.

## II.5. Les résultats

Le modèle obtenu fournit des résultats qui, bien que suffisants pour une preuve de concept, sont significativement en dessous de la qualité nécessaire pour être exploitable. Ces résultats étaient attendus, car cette partie du stage visait principalement à se familiariser avec les données et à explorer les possibilités en terme de fusion d'images. Les prédictions du modèle sont toutefois convaincantes, comme on peut le voir en figure FIGURE 7. Il est aussi intéressant de voir que si l'on remplace la partie saturée des images les plus exposées par les prédictions du modèle, on obtient une approximation de bonne qualité des SPST (FIGURE 8).

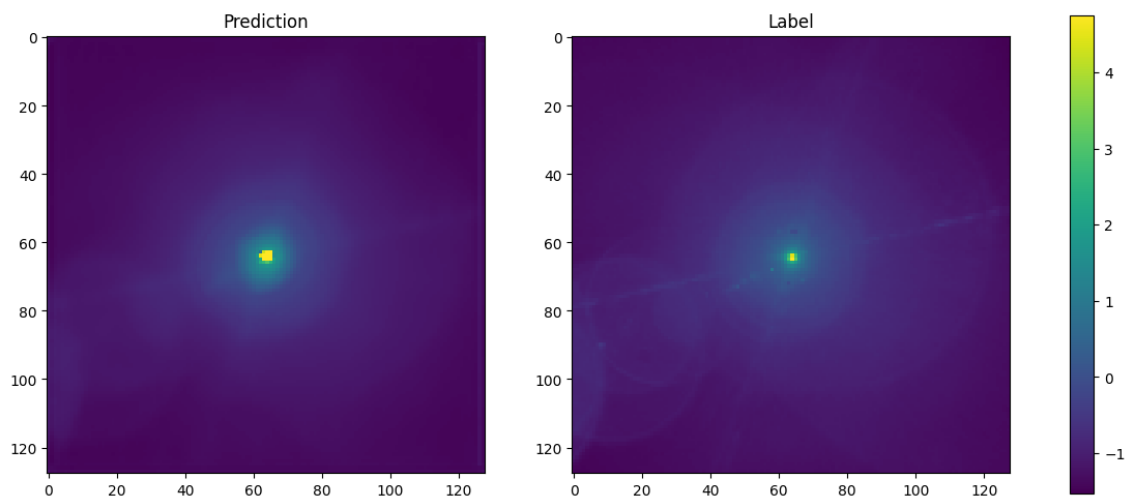


FIGURE 7 – La fusion du modèle et l'image label




FIGURE 8 – La prédiction du modèle encapsulée



### III. L'interpolation d'images

La seconde partie du stage consistait à tenter de reproduire les résultats de l'interpolation à l'aide de techniques de deep learning. Le but est, à partir d'une grille de calibration de  $k \times k$ , d'interpoler une grille de  $n \times n$  avec  $n > k$ . Les valeurs retenues de  $k$  et  $n$  sont 27 et 64.

#### III.1. Définition des FPST

La méthode utilisée est basée sur le concept de FPST (field point source transmittance). Ces dernières sont l'inverse des SPST, à savoir pour un pixel du détecteur donné, la carte de la quantité de lumière parasite reçue depuis les différents champs calibrés. La résolution dépend alors du nombre de champs calibrés, et pour une grille de calibration de  $27 \times 27$ , on aura des FPST de résolution  $27 \times 27$ . Du point de vue du deep learning, ces cartes sont bien plus intéressantes à manipuler que les SPST, car elles sont plus petites, mais bien plus nombreuses (dans tous les cas, il y en a  $512 \times 512 = 262,144$ ).

Les données disponibles étaient les SPST calibrées sur la grille originelle de  $27 \times 27$ , et des interpolations réalisées par l'équipe de chercheurs en charge du détecteur 3MI sur des grilles de  $64 \times 64$  et  $128 \times 128$ . Comme établi précédemment, seules les grilles  $27 \times 27$  et  $64 \times 64$  seront utilisées.

Pour pouvoir utiliser les FPST, il faut au préalable les calculer. La méthode est la suivante : pour une grille de calibration de  $k \times k$ , chaque pixel des SPST correspond à une FPST. En prenant le pixel  $i,j$  de chaque SPST, on arrive donc à extraire la  $FPST_{i,j}$ . On voit donc que pour calculer une FPST, il faut boucler sur toutes les SPST, et qu'il faut faire cela pour les 200,000 pixels des SPST. Même en optimisant le code, c'est un calcul qui prend plusieurs heures. On ne le réalise donc qu'une seule fois, et on stocke les résultats.

#### III.2. La méthode choisie

Une propriété intéressante des FPST est que leur résolution est directement corrélée à la densité de la grille de calibration. Le problème de l'interpolation de la grille de calibration peut donc être interprété comme un problème d'augmentation de résolution entre une image de  $27 \times 27$  pixels et une image de  $64 \times 64$  pixels. Ce problème, nommé "super resolution", est un problème commun en deep learning, et très documenté. Les modèles étudiés sont basés sur l'article de blog *Image Super-Resolution : A Comprehensive Review* [2], qui compile de nombreux articles et études sur le sujet.

Pour passer d'une image de  $27 \times 27$  pixels à une image de  $64 \times 64$  pixels, on

utilise d'abord une technique de base de l'augmentation de résolution (plus proche voisin), pour passer d'une image de  $27 \times 27$  pixels à une image de  $32 \times 32$  pixels. On utilisera alors un réseau de deep learning pour doubler la résolution et améliorer la qualité de la prédiction. On utilise cette méthode car les tailles en puissance de deux sont plus simple à gérer par des réseaux de neurones.

### III.3. Les différents modèles

Dans l'article de blog *Image Super-Resolution : A Comprehensive Review* [2], différents modèles adaptés à la tâche de la super-resolution sont présentés. Ils sont divisés en 2 catégories :

#### III.3.a. Super-resolution en amont

Les méthodes de super résolution en amont augmentent d'abord la résolution des images avec des techniques basiques d'interpolation. Puis, elles utilisent le deep learning pour affiner l'image et restaurer les caractéristiques spatiales fines.

SRCNN (super resolution convolutional neural network) est une architecture de réseau convolutionnel très épurée. Elle est composée de trois couches. La première couche est constituée d'un grand nombre de filtres de convolutions. Ceux-ci permettent d'extraire les caractéristiques de l'image. La deuxième couche se compose de filtres de convolution  $1 \times 1$  utilisés pour ajouter de la non-linéarité. La couche de reconstruction finale reconstitue l'image en haute résolution.

VDSR (very deep super resolution) est une architecture similaire à SRCNN. Le réseau est plus profond et de petits filtres de convolution  $3 \times 3$  sont utilisés au lieu d'un réseau plus petit avec de grands filtres de convolution. Le réseau tente d'apprendre la différence entre l'image d'entrée augmentée par des techniques d'interpolation et l'image de référence haute résolution. Pour obtenir l'image haute résolution finale, on ajoute donc la sortie du réseau à l'image d'entrée.

#### III.3.b. Super-resolution en aval

La super-resolution en aval ne touche pas aux images basse résolution avant l'entrée dans le modèle. L'extraction de caractéristiques se fait dans l'espace de basse résolution et l'augmentation de résolution est faite par le réseau. Le fait que les opérations se déroulent dans l'espace basse résolution confère l'avantage d'avoir des calculs plus faciles. De plus, l'augmentation de résolution étant réalisées par des couches entraînaibles du modèle, tout le processus est entraînable ce qui permet une plus grande capacité du modèle.

FSRCNN (faster super resolution cnn) reprend les principes de SRCNN avec

des différences importantes. Le modèle implémente la stratégie de super-resolution en aval, il n'y a donc pas d'interpolation avant le modèle. De plus, les couches d'extraction de caractéristiques sont situées en espace de basse dimension. De même que pour VDSR, on remplace la grosse couche convolutionnelle par plusieurs petites couches. Enfin, l'augmentation de résolution est effectuée par des couches spéciales à la fin du réseau. Ces couches sont des couches de déconvolutions, qui fonctionnent comme l'inverse d'une convolution, et dont le principe est de prédire l'entrée qui aurait conduit à une sortie correspondant à l'entrée.

ESPCNN (efficient sub-pixel cnn) est une architecture similaire à FSRCNN, où les couches de déconvolution sont remplacées par des couches de convolution sub-pixel. Ces couches présentent deux avantages sur les couches de déconvolution. Tout d'abord, la déconvolution se produit dans l'espace haute résolution, ce qui la rend plus coûteuse en terme de calcul. De plus, ces dernières peuvent amener un problème d'homogénéité de la répartition de l'information inhérent aux convolutions à cause du chevauchement des filtres.

La convolution sub-pixel fonctionne en convertissant la profondeur des différentes couches des filtres de convolution en espace. Si l'on souhaite doubler la taille d'une image, on crée une convolution avec 4 filtres (2x2) qui aura donc en sortie 4 images de taille basse résolution. En alternant les pixels des 4 images dans un motif régulier, on obtient alors l'image haute résolution.

### III.3.c. Choix du modèle

Au cours des différentes expérimentations avec les modèles, les modèles de super résolution en aval sont vite apparus comme les plus adaptés à la tâche présente. ESPCNN étant plus facile à entraîner que FSRCNN et présentant sur les tests des performances similaires et même légèrement meilleures, c'est ce dernier que l'on utilise.

### III.4. Les hyperparamètres

Le surapprentissage n'étant pas un problème aussi sérieux pour la super résolution que pour la fusion d'images, l'exploration des hyperparamètres est concentrée sur l'optimisation de la performance du modèle. Toutefois on applique toujours l'arrêt prématuré, car cela permet de conserver le meilleur modèle de l'entraînement.

Pour cette partie du stage, l'implémentation d'un grid search a été concluante. Deux recherches ont été effectuées. La première comparait différentes valeurs des paramètres suivants : learning rate, architecture du modèle (nombre de couches de convolution et nombre filtres dans la première et deuxième convolution) et type de convolution appliquées (convolution simple, avec batch normalisation, avec une activation leaky ReLu, ou les deux). Les résultats de cette recherche sont exposés dans la TABLE 1.

learning_rate	num_layers	num_filters_1	num_filters_2	conv_block	loss
0.001	9	128	64	conv_block	0.000009
0.001	17	128	64	conv_block_bn	0.000010
0.001	9	64	32	conv_block	0.000010
0.001	9	128	64	conv_block_bn	0.000011
0.001	17	64	32	conv_block_bn	0.000011
0.001	9	128	64	conv_block_bn_leaky	0.000011
0.001	17	64	32	conv_block	0.000011
0.001	17	128	64	conv_block	0.000011
0.001	9	64	32	conv_block_leaky	0.000012
0.001	17	128	64	conv_block_bn_leaky	0.000012

TABLE 1 – Résultat du premier grid search

On remarque d'abord que la valeur de base de Adam pour le learning rate (0.001) est la meilleure. On laissera donc la valeur par défaut pour la seconde recherche. De plus, l'activation leaky ReLu est toujours pire que ses contreparties. On ne la testera donc pas dans la seconde recherche. On profite de cette réduction des paramètres à tester pour tester des tailles de modèle plus volumineuses. On abandonne les tailles les plus petites, et on rajoute une catégorie de taille. De plus on teste différentes fonctions d'initialisation et différentes valeurs de dropout. Les résultats de cette recherches sont présentés en TABLE 2

num_layers	num_filters_1	num_filters_2	batch_norm	dropout_rate	init	loss
17	128	64	True	0.0	he_normal	0.000008
33	128	64	False	0.0	glorot_uniform	0.000008
33	128	64	False	0.0	lecun_normal	0.000009
17	128	64	False	0.0	glorot_uniform	0.000009
17	128	64	False	0.0	he_normal	0.000009
33	128	64	True	0.0	he_normal	0.000009
17	128	64	True	0.0	lecun_normal	0.000010
9	128	64	False	0.0	he_normal	0.000011
9	128	64	False	0.0	glorot_uniform	0.000011
17	128	64	False	0.0	lecun_normal	0.000011

TABLE 2 – Résultat du deuxième grid search

### III.5. Les résultats

En utilisant les hyperparamètres les plus performants de la deuxième recherche, on lance une entraînement avec un taille du batch de 1 (une taille de 16 avait été utilisée dans le grid search pour limiter le temps de calcul). L'historique de cet entraînement est présenté en FIGURE 9.




FIGURE 9 – Historique de l'entraînement du modèle

La FIGURE 10 présente un exemple de prédiction du modèle de super résolution. Sont comparé l'image originelle (agrandie à 32x32 pixels), l'image de référence et la prédiction du modèle.




FIGURE 10 – FPST en basse résolution, prédiction et label en haute résolution

La FIGURE 11 compare une SPST et son équivalent reconstruit à partir des FPST prédites par le modèle.

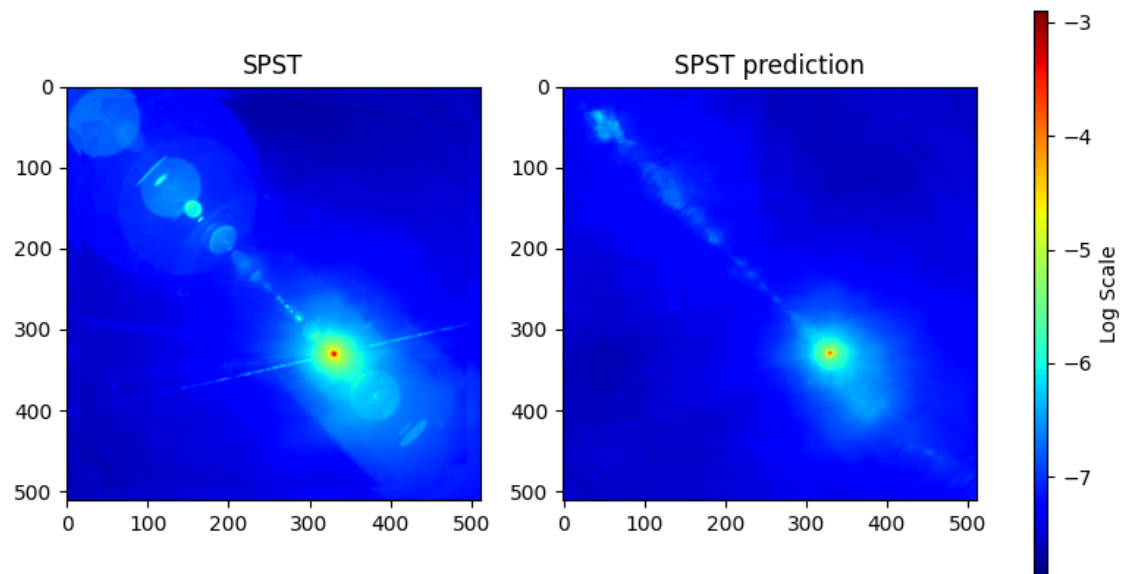


FIGURE 11 – Reconstruction d'une SPST basée sur les prédiction des FPST

## Conclusion

La mission entreprise au sein du Centre Spatial de Liège avait pour objectif principal d'améliorer les performances des instruments optiques, en particulier l'instrument d'observation de la Terre, 3MI. À travers cette expérience, nous avons non seulement relevé les défis techniques liés à la correction de la lumière parasite dans le domaine spatial, mais nous avons également exploré les possibilités offertes par l'apprentissage profond pour résoudre ces défis complexes.

Dans un premier temps, nous avons mis en lumière l'importance cruciale de la correction de la lumière parasite dans le succès des missions spatiales et la qualité des données collectées. Le Centre Spatial de Liège s'est révélé être un acteur de premier plan dans la recherche de solutions innovantes à ce problème complexe, grâce à ses contributions significatives à la conception d'instruments optiques de haute précision.

Le travail effectué au cours de ce stage s'est articulé autour de deux axes majeurs. Tout d'abord, nous avons abordé la question de la recherche des meilleures combinaisons d'hyperparamètres pour un modèle UNet utilisé dans la fusion d'images. Malgré les défis initiaux, nous avons réussi à mettre en place des processus d'expérimentation robustes, intégrant des techniques telles que le dropout, la batch normalization et l'early stopping, ce qui a permis d'obtenir un modèle satisfaisant.

Ensuite, nous nous sommes attaqués à l'interpolation d'images en utilisant des techniques de deep learning pour augmenter la résolution des images de 27x27 à 64x64. Différentes architectures de modèles de super-résolution ont été explorées, offrant ainsi une solution prometteuse pour résoudre ce défi.

Pour conclure, cette expérience au Centre Spatial de Liège a permis de contribuer activement à la recherche visant à améliorer les performances des instruments optiques spatiaux. Ce travail ouvre la voie à de nouvelles opportunités dans le domaine de la correction de la lumière parasite et de l'augmentation de la résolution des images spatiales. Il s'inscrit dans un contexte plus large de recherche en amélioration des instruments optiques, contribuant ainsi à renforcer la position du CSL en tant qu'acteur clé de l'exploration spatiale et de l'observation de la Terre.

Ce stage a été une expérience enrichissante, combinant apprentissage théorique, pratique et recherche de solutions innovantes. Nous espérons que les résultats obtenus serviront de base solide pour de futures avancées dans ce domaine passionnant de la science spatiale.

## Bibliographie

- [1] Hui LI et Lei ZHANG. « Multi-Exposure Fusion with CNN Features ». In : *2018 25th IEEE International Conference on Image Processing (ICIP)*. 2018, p. 1723-1727. DOI : 10.1109/ICIP.2018.8451689.
- [2] Anil Chandra Naidu MATCHA. *Image Super-Resolution : A Comprehensive Review*. 2020. URL : <https://blog.paperspace.com/image-super-resolution/>.
- [3] Han XU, Jiayi MA et Xiao-Ping ZHANG. « MEF-GAN : Multi-Exposure Image Fusion via Generative Adversarial Networks ». In : *IEEE Transactions on Image Processing* 29 (2020), p. 7203-7216. DOI : 10.1109/TIP.2020.2999855.
- [4] Yu ZHANG et al. « IFCNN : A general image fusion framework based on convolutional neural network ». In : *Information Fusion* 54 (2020), p. 99-118. ISSN : 1566-2535. DOI : <https://doi.org/10.1016/j.inffus.2019.07.011>. URL : <https://www.sciencedirect.com/science/article/pii/S1566253518305505>.
- [5] Xingchen ZHANG. « Benchmarking and comparing multi-exposure image fusion algorithms ». In : *Information Fusion* 74 (2021), p. 111-131. ISSN : 1566-2535. DOI : <https://doi.org/10.1016/j.inffus.2021.02.005>. URL : <https://www.sciencedirect.com/science/article/pii/S1566253521000233>.
- [6] Lionel CLERMONT, Céline MICHEL et Yvan STOCKMAN. « Stray Light Correction Algorithm for High Performance Optical Instruments : The Case of Metop-3MI ». In : *Remote Sensing* 14.6 (2022). ISSN : 2072-4292. DOI : 10.3390/rs14061354. URL : <https://www.mdpi.com/2072-4292/14/6/1354>.
- [7] Lionel CLERMONT. « Stray light control in space instruments : overcoming the conventional limits ». Anglais. Thèse de doct. ULiège - Université de Liège, 9June 2021.